

Ejercicios Resueltos de Optimización y Análisis de Redes

Víctor Aceña Gil

Antonio Alonso Ayuso

Índice de Soluciones

Introducción	3
1 Ejercicios Resueltos del Tema 2: optimización no lineal y métodos numéricos	4
1.1 Ejercicio 1: duopolio de Cournot con costes cuadráticos	4
1.1.1 Apartado 1: Formulación del problema y funciones de reacción	4
1.1.2 Apartado 2: Equilibrio de Cournot-Nash	5
1.1.3 Apartado 3: Análisis de la convexidad del beneficio	6
1.2 Ejercicio 2: caracterización de curvatura y convexidad	7
1.2.1 Apartado 1: Convexidad de $f(x, y) = e^{x^2+y^2}$	7
1.2.2 Apartado 2: Convexidad de $f(x, y) = 2x^2 - 4xy + y^4$	8
1.2.3 Apartado 3: Convexidad de $f(x, y) = -\ln(x) - \ln(y)$	8
1.3 Ejercicio 3: clasificación de puntos estacionarios	9
1.3.1 Apartado 1: Localización de puntos críticos	9
1.3.2 Apartado 2: Clasificación de puntos críticos	10
1.3.3 Apartado 3: Análisis de óptimos globales	11
1.4 Ejercicio 4: trazado de búsqueda áurea y Newton 1D	11
1.4.1 Apartado 1: Paso 1 del método de la sección áurea	12
1.4.2 Apartado 2: Paso 1 del método de Newton 1D	12
1.5 Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales . . .	13
1.5.1 Apartado 1: Búsqueda lineal en la variable x	13
1.5.2 Apartado 2: Búsqueda lineal en la variable y	14
1.5.3 Apartado 3: Análisis de convergencia y acoplamiento	14
1.6 Ejercicio 6: máximo descenso: invarianza ortogonal y trazado	15
1.6.1 Apartado 1: Gradiente y dirección de búsqueda inicial	15
1.6.2 Apartado 2: Búsqueda lineal exacta y actualización de puntos	16
1.6.3 Apartado 3: Verificación del Teorema de Ortogonalidad	16
1.7 Ejercicio 7: Newton multivariante: convergencia cuadrática	17
1.7.1 Apartado 1: Gradiente y Hessiana iniciales	17
1.7.2 Apartado 2: Cálculo de la inversa de la Hessiana	17
1.7.3 Apartado 3: Actualización e interpretación física de la convergencia . .	18

Introducción

Este cuaderno recopila las **soluciones detalladas** a los ejercicios propuestos para la asignatura **Optimización y Análisis de Redes**.

Cada ejercicio contiene tanto la demostración matemática formal como la implementación de código en Python correspondiente para verificar las soluciones de manera numérica.

1 Ejercicios Resueltos del Tema 2: optimización no lineal y métodos numéricos

1.1 Ejercicio 1: duopolio de Cournot con costes cuadráticos

Dos empresas competidoras, Empresa 1 y Empresa 2, producen un bien de consumo homogéneo. La función de demanda inversa de mercado viene dada por:

$$P(Q) = 20 - Q$$

donde $Q = Q_1 + Q_2$ es la producción total acumulada en el mercado. Las funciones de coste total de cada empresa son cuadráticas y se definen como:

$$C_1(Q_1) = 2Q_1 + \frac{1}{2}Q_1^2 \quad \text{y} \quad C_2(Q_2) = 3Q_2 + Q_2^2$$

Las producciones están limitadas físicamente por capacidades máximas: $Q_1 \leq 8$ y $Q_2 \leq 6$, y no pueden ser negativas.

1.1.1 Apartado 1: Formulación del problema y funciones de reacción

Formular el problema de optimización individual de cada empresa para maximizar sus beneficios, determinando sus funciones de reacción o mejor respuesta $Q_1^*(Q_2)$ y $Q_2^*(Q_1)$.

Ver solución del Apartado 1

Resolución matemática:

1. **Empresa 1:** El beneficio B_1 se define como la diferencia entre los ingresos y el coste total:

$$\begin{aligned} B_1(Q_1, Q_2) &= P(Q_1 + Q_2) \cdot Q_1 - C_1(Q_1) \\ B_1(Q_1, Q_2) &= (20 - Q_1 - Q_2)Q_1 - \left(2Q_1 + \frac{1}{2}Q_1^2\right) = 18Q_1 - \frac{3}{2}Q_1^2 - Q_1Q_2 \end{aligned}$$

Para maximizar, derivamos respecto a Q_1 e igualamos a cero (FONC):

$$\frac{\partial B_1}{\partial Q_1} = 18 - 3Q_1 - Q_2 = 0 \implies 3Q_1 = 18 - Q_2 \implies Q_1^*(Q_2) = 6 - \frac{Q_2}{3}$$

Como $Q_2 \geq 0$, la función de mejor respuesta de la Empresa 1 satisface $Q_1^*(Q_2) \leq 6 \leq 8$, por lo que la restricción de capacidad máxima $Q_1 \leq 8$ no se satura y se cumple de forma inactiva.

2. **Empresa 2:** Su beneficio B_2 viene dado por:

$$B_2(Q_1, Q_2) = P(Q_1 + Q_2) \cdot Q_2 - C_2(Q_2)$$

$$B_2(Q_1, Q_2) = (20 - Q_1 - Q_2)Q_2 - (3Q_2 + Q_2^2) = 17Q_2 - 2Q_2^2 - Q_1Q_2$$

Derivando respecto a Q_2 e igualando a cero (FONC):

$$\frac{\partial B_2}{\partial Q_2} = 17 - 4Q_2 - Q_1 = 0 \implies 4Q_2 = 17 - Q_1 \implies Q_2^*(Q_1) = 4.25 - \frac{Q_1}{4}$$

De nuevo, dado que $Q_1 \geq 0$, se cumple que $Q_2^*(Q_1) \leq 4.25 \leq 6$, por lo que la restricción $Q_2 \leq 6$ tampoco se satura.

1.1.2 Apartado 2: Equilibrio de Cournot-Nash

Calcular analíticamente el equilibrio de Cournot-Nash del mercado (el punto donde ambas decisiones son óptimas simultáneamente).

Ver solución del Apartado 2

Resolución matemática:

El equilibrio de Cournot-Nash se encuentra resolviendo el sistema lineal de ecuaciones formado por las dos funciones de reacción:

$$\begin{cases} 3Q_1 + Q_2 = 18 \\ Q_1 + 4Q_2 = 17 \end{cases}$$

Despejando y resolviendo el sistema: * De la segunda ecuación: $Q_1 = 17 - 4Q_2$. * Sustituyendo en la primera:

$$3(17 - 4Q_2) + Q_2 = 18 \implies 51 - 12Q_2 + Q_2 = 18 \implies 11Q_2 = 33 \implies Q_2^* = 3$$

* Calculando Q_1 :

$$Q_1^* = 17 - 4(3) = 5$$

El **equilibrio de Cournot-Nash** es:

$$(Q_1^*, Q_2^*) = (5, 3)$$

El precio de mercado resultante es:

$$P^* = 20 - (5 + 3) = 12 \text{ u.m.}$$

Los beneficios en el equilibrio de Nash de cada empresa son: * Empresa 1: $B_1^* = 12 \cdot 5 - 2 \cdot 5 - 0.5 \cdot 5^2 = 60 - 10 - 12.5 = 37.5$ u.m. * Empresa 2: $B_2^* = 12 \cdot 3 - 3 \cdot 3 - 3^2 = 36 - 9 - 9 = 18$ u.m.

1.1.3 Apartado 3: Análisis de la convexidad del beneficio

Analizar la convexidad de las funciones de beneficio de cada empresa y discutir si el problema de optimización resultante es convexo.

Ver solución del Apartado 3

Resolución matemática:

1. **Convexidad del problema individual:** El problema de cada empresa es un problema de maximización de beneficios. En el contexto de optimización, un problema de maximización es convexo si la función objetivo es cóncava y el conjunto factible es convexo (lo cual se cumple ya que los intervalos de producción $[0, 8]$ y $[0, 6]$ son conjuntos convexos). Analicemos la segunda derivada de las funciones de beneficio individuales:

- Empresa 1: $\frac{\partial^2 B_1}{\partial Q_1^2} = -3 < 0$. Al ser la segunda derivada estrictamente negativa para cualquier punto, B_1 es estrictamente cóncava respecto a Q_1 .
- Empresa 2: $\frac{\partial^2 B_2}{\partial Q_2^2} = -4 < 0$. Por tanto, B_2 es estrictamente cóncava respecto a Q_2 .
- **Conclusión:** Ambos problemas de optimización individuales son estrictamente convexos.

2. **Verificación del equilibrio en Python:** Podemos validar el cálculo y la concavidad de forma simbólica usando el siguiente script en Python:

```
import sympy as sp

Q1, Q2 = sp.symbols('Q1 Q2')
B1 = (20 - Q1 - Q2)*Q1 - 2*Q1 - 0.5*Q1**2
B2 = (20 - Q1 - Q2)*Q2 - 3*Q2 - Q2**2

# Derivadas parciales de primer orden (FONC)
dB1 = sp.diff(B1, Q1)
dB2 = sp.diff(B2, Q2)

# Resolver sistema para el equilibrio de Nash
```

```

eq = sp.solve([dB1, dB2], (Q1, Q2))
print("Equilibrio de Nash (Q1, Q2):", eq)

# Verificar segundas derivadas (Concavidad)
d2B1 = sp.diff(B1, Q1, 2)
d2B2 = sp.diff(B2, Q2, 2)
print("Segunda derivada B1:", d2B1)
print("Segunda derivada B2:", d2B2)

```

1.2 Ejercicio 2: caracterización de curvatura y convexidad

Analizar la convexidad de las siguientes funciones en sus respectivos dominios utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores:

1.2.1 Apartado 1: Convexidad de $f(x, y) = e^{x^2+y^2}$

Ver solución del Apartado 1

Resolución matemática:

1. Gradiente de primer orden:

$$\frac{\partial f}{\partial x} = 2xe^{x^2+y^2} \quad y \quad \frac{\partial f}{\partial y} = 2ye^{x^2+y^2}$$

2. Matriz hessiana (H): Calculando las segundas derivadas:

$$\frac{\partial^2 f}{\partial x^2} = (2 + 4x^2)e^{x^2+y^2} \quad \frac{\partial^2 f}{\partial y^2} = (2 + 4y^2)e^{x^2+y^2}$$

$$\frac{\partial^2 f}{\partial x \partial y} = 4xye^{x^2+y^2}$$

Por lo tanto:

$$H(x, y) = e^{x^2+y^2} \begin{pmatrix} 2 + 4x^2 & 4xy \\ 4xy & 2 + 4y^2 \end{pmatrix}$$

3. Menores principales:

- $M_1 = e^{x^2+y^2}(2 + 4x^2) > 0$ (ya que la función exponencial es siempre estrictamente positiva y $2 + 4x^2 \geq 2$).

- $M_2 = \det(H) = e^{2(x^2+y^2)} [(2+4x^2)(2+4y^2) - 16x^2y^2]$

$$M_2 = e^{2(x^2+y^2)} [4 + 8x^2 + 8y^2 + 16x^2y^2 - 16x^2y^2] = e^{2(x^2+y^2)} [4 + 8x^2 + 8y^2] > 0$$

- **Conclusión:** Dado que todos los menores principales son estrictamente positivos para cualquier $(x, y) \in \mathbb{R}^2$, la matriz hessiana es definida positiva ($H \succ 0$). Por tanto, la función es **estrictamente convexa** en todo su dominio $\mathbb{R}^2$.

1.2.2 Apartado 2: Convexidad de $f(x, y) = 2x^2 - 4xy + y^4$

Ver solución del Apartado 2

Resolución matemática:

1. **Gradiente:**

$$\frac{\partial f}{\partial x} = 4x - 4y \quad \text{y} \quad \frac{\partial f}{\partial y} = -4x + 4y^3$$

2. **Matriz hessiana (H):**

$$H(x, y) = \begin{pmatrix} 4 & -4 \\ -4 & 12y^2 \end{pmatrix}$$

3. **Menores principales:**

- $M_1 = 4 > 0$.
- $M_2 = \det(H) = 48y^2 - 16 = 16(3y^2 - 1)$.
- **Análisis:** Para que la función sea convexa en su dominio, la hessiana debe ser semidefinida positiva para todo $(x, y) \in \mathbb{R}^2$. Sin embargo, vemos que M_2 depende del valor de la variable y :
 - Si $3y^2 - 1 < 0 \implies |y| < \frac{1}{\sqrt{3}}$, entonces $M_2 < 0$. Al ser el determinante negativo, la matriz es indefinida.
- **Conclusión:** La función **no es convexa en todo el dominio** $\mathbb{R}^2$ (únicamente exhibe convexidad local en el espacio donde se satisface $|y| \geq \frac{1}{\sqrt{3}}$).

1.2.3 Apartado 3: Convexidad de $f(x, y) = -\ln(x) - \ln(y)$

Ver solución del Apartado 3

Resolución matemática:

1. **Gradiente:**

$$\frac{\partial f}{\partial x} = -\frac{1}{x} \quad \text{y} \quad \frac{\partial f}{\partial y} = -\frac{1}{y}$$

2. Matriz hessiana (H):

$$H(x, y) = \begin{pmatrix} 1/x^2 & 0 \\ 0 & 1/y^2 \end{pmatrix}$$

3. Menores principales: En el dominio $\mathbb{R}_{++}^2$ se tiene que:

- $M_1 = \frac{1}{x^2} > 0$ (ya que $x > 0$).
- $M_2 = \det(H) = \frac{1}{x^2 y^2} > 0$ (ya que $x, y > 0$).
- **Conclusión:** Al ser los menores principales estrictamente positivos en todo el dominio de definición de la función, la hessiana es definida positiva ($H \succ 0$) y la función es **estrictamente convexa** en $\mathbb{R}_{++}^2$.

4. Validación en Python (SymPy):

```
import sympy as sp

x, y = sp.symbols('x y', real=True)

# Caso 2: f(x, y) = 2x^2 - 4xy + y^4
f2 = 2*x**2 - 4*x*y + y**4
H2 = sp.hessian(f2, (x, y))
print("Hessiana de f2:\n", H2)
print("Determinante de H2:", H2.det())
```

1.3 Ejercicio 3: clasificación de puntos estacionarios

Considerar la siguiente función real de dos variables:

$$f(x, y) = x^3 + y^3 - 3x - 12y + 20$$

1.3.1 Apartado 1: Localización de puntos críticos

Encontrar todos los puntos críticos o estacionarios de la función aplicando las condiciones de primer orden (FONC).

Ver solución del Apartado 1

Resolución matemática:

Las condiciones necesarias de primer orden (FONC) exigen que el vector gradiente sea nulo:

$$\nabla f(x, y) = \begin{pmatrix} 3x^2 - 3 \\ 3y^2 - 12 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Esto genera un sistema de dos ecuaciones independientes: 1. $3x^2 - 3 = 0 \implies x^2 = 1 \implies x = \pm 1$. 2. $3y^2 - 12 = 0 \implies y^2 = 4 \implies y = \pm 2$.

Combinando todas las soluciones posibles, obtenemos **cuatro puntos críticos**: * $P_1 = (1, 2)$ * $P_2 = (1, -2)$ * $P_3 = (-1, 2)$ * $P_4 = (-1, -2)$

1.3.2 Apartado 2: Clasificación de puntos críticos

Clasificar cada uno de los puntos estacionarios hallados utilizando el criterio de la matriz hessiana y las condiciones de segundo orden (SOSC).

Ver solución del Apartado 2

Resolución matemática:

Calculamos la matriz hessiana general para la función:

$$H(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 6y \end{pmatrix}$$

Al ser una matriz diagonal, sus autovalores son directamente los elementos de la diagonal principal: $\lambda_1 = 6x$ y $\lambda_2 = 6y$. Evaluamos cada uno de los cuatro puntos:

1. **Punto** $P_1 = (1, 2)$:

$$H(1, 2) = \begin{pmatrix} 6 & 0 \\ 0 & 12 \end{pmatrix} \implies \lambda_1 = 6 > 0, \quad \lambda_2 = 12 > 0$$

Hessiana definida positiva ($H \succ 0$). Por tanto, P_1 es un **mínimo local estricto**. Valor de la función: $f(1, 2) = 1^3 + 2^3 - 3(1) - 12(2) + 20 = 2$.

2. **Punto** $P_2 = (1, -2)$:

$$H(1, -2) = \begin{pmatrix} 6 & 0 \\ 0 & -12 \end{pmatrix} \implies \lambda_1 = 6 > 0, \quad \lambda_2 = -12 < 0$$

Hessiana indefinida (autovalores de distinto signo). Por tanto, P_2 es un **punto de silla**. Valor de la función: $f(1, -2) = 1^3 + (-2)^3 - 3(1) - 12(-2) + 20 = 34$.

3. **Punto** $P_3 = (-1, 2)$:

$$H(-1, 2) = \begin{pmatrix} -6 & 0 \\ 0 & 12 \end{pmatrix} \Rightarrow \lambda_1 = -6 < 0, \quad \lambda_2 = 12 > 0$$

Hessiana indefinida. Por tanto, P_3 es un **punto de silla**. Valor de la función: $f(-1, 2) = (-1)^3 + 2^3 - 3(-1) - 12(2) + 20 = 6$.

4. **Punto** $P_4 = (-1, -2)$:

$$H(-1, -2) = \begin{pmatrix} -6 & 0 \\ 0 & -12 \end{pmatrix} \Rightarrow \lambda_1 = -6 < 0, \quad \lambda_2 = -12 < 0$$

Hessiana definida negativa ($H \prec 0$). Por tanto, P_4 es un **máximo local estricto**. Valor de la función: $f(-1, -2) = (-1)^3 + (-2)^3 - 3(-1) - 12(-2) + 20 = 38$.

1.3.3 Apartado 3: Análisis de óptimos globales

Determinar razonadamente si la función posee algún mínimo global o máximo global sobre todo el dominio $\mathbb{R}^2$.

Ver solución del Apartado 3

Resolución matemática:

La función **no posee óptimos globales** sobre $\mathbb{R}^2$ por falta de acotación: * Si fijamos $y = 0$ y hacemos tender $x \rightarrow +\infty$: $\lim_{x \rightarrow +\infty} f(x, 0) = \lim_{x \rightarrow +\infty} (x^3 - 3x + 20) = +\infty$. * Si fijamos $y = 0$ y hacemos tender $x \rightarrow -\infty$: $\lim_{x \rightarrow -\infty} f(x, 0) = \lim_{x \rightarrow -\infty} (x^3 - 3x + 20) = -\infty$.

Dado que la función no está acotada superior ni inferiormente en $\mathbb{R}^2$, los mínimos y máximos locales hallados no pueden extender su validez de manera global.

1.4 Ejercicio 4: trazado de búsqueda áurea y Newton 1D

Se desea encontrar el mínimo global de la función real:

$$f(x) = x \ln(x) - 1.5x$$

en el intervalo acotado $[1, 3]$. Se sabe que el mínimo analítico exacto se encuentra en $x^* = e^{0.5} \approx 1.6487$.

1.4.1 Apartado 1: Paso 1 del método de la sección áurea

Ver solución del Apartado 1

Resolución matemática:

1. **Amplitud de búsqueda inicial:** El intervalo inicial es $[a_0, b_0] = [1, 3]$. Su amplitud es $b_0 - a_0 = 2.0$.
2. **Amplitud de reducción I_1 :** Utilizando la razón áurea $\alpha \approx 1.61803$:

$$I_1 = \frac{b_0 - a_0}{\alpha} = \frac{2.0}{1.61803} \approx 1.2361$$

3. **Puntos de evaluación iniciales:**

$$\lambda_0 = b_0 - I_1 = 3 - 1.2361 = 1.7639$$

$$\mu_0 = a_0 + I_1 = 1 + 1.2361 = 2.2361$$

4. **Evaluación de la función:**

- $f(\lambda_0) = f(1.7639) = 1.7639 \ln(1.7639) - 1.5(1.7639) \approx -1.6449$
- $f(\mu_0) = f(2.2361) = 2.2361 \ln(2.2361) - 1.5(2.2361) \approx -1.5548$

5. **Descarte de intervalos:** Como $f(\lambda_0) < f(\mu_0)$ (es decir, $-1.6449 < -1.5548$), el mínimo no puede encontrarse en el subintervalo $[\mu_0, b_0]$. Por lo tanto, descartamos la porción derecha del dominio. El **nuevo intervalo** para la siguiente iteración es:

$$[a_1, b_1] = [a_0, \mu_0] = [1.0, 2.2361]$$

Su amplitud es 1.2361, que resulta mayor que la tolerancia $\epsilon = 0.5$, por lo que el algoritmo continuaría.

1.4.2 Apartado 2: Paso 1 del método de Newton 1D

Ver solución del Apartado 2

Resolución matemática:

1. **Ecuaciones de las derivadas:**

- Función: $f(x) = x \ln(x) - 1.5x$
- Primera derivada: $f'(x) = \ln(x) + x \left(\frac{1}{x}\right) - 1.5 = \ln(x) - 0.5$
- Segunda derivada: $f''(x) = \frac{1}{x}$

2. **Evaluación en el punto inicial $x_0 = 1.0$:**

- $f'(1.0) = \ln(1.0) - 0.5 = -0.5$

- $f''(1.0) = \frac{1}{1.0} = 1.0$

3. Actualización de Newton:

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.0 - \frac{-0.5}{1.0} = 1.5$$

La aproximación $x_1 = 1.5$ se sitúa notablemente cerca del óptimo analítico exacto $x^* \approx 1.6487$ en un único paso debido a que la función objetivo presenta una curvatura muy bien aproximada cuadráticamente en el entorno de x_0 .

1.5 Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales

Dada la función cuadrática de dos variables con acoplamiento:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

1.5.1 Apartado 1: Búsqueda lineal en la variable x

Ver solución del Apartado 1

Resolución matemática:

Partimos de $x_0 = (0, 0)^T$. Optimizamos respecto a la primera dirección coordenada $e_1 = (1, 0)^T$ fijando la variable $y = 0$:

$$f(x, 0) = 3x^2 + 2x(0) + (0)^2 - 4x - 2(0) = 3x^2 - 4x$$

Minimizamos esta función de una sola variable derivando e igualando a cero:

$$\frac{df(x, 0)}{dx} = 6x - 4 = 0 \implies x = \frac{4}{6} = \frac{2}{3} \approx 0.6667$$

El punto resultante al término de la primera búsqueda lineal es:

$$x_1 = \left(\frac{2}{3}, 0\right)^T$$

1.5.2 Apartado 2: Búsqueda lineal en la variable y

Ver solución del Apartado 2

Resolución matemática:

Fijando $x = x_1 = 2/3$, optimizamos ahora respecto a la segunda dirección coordenada $e_2 = (0, 1)^T$:

$$\begin{aligned}f(2/3, y) &= 3 \left(\frac{2}{3}\right)^2 + 2 \left(\frac{2}{3}\right) y + y^2 - 4 \left(\frac{2}{3}\right) - 2y \\f(2/3, y) &= \frac{4}{3} + \frac{4}{3}y + y^2 - \frac{8}{3} - 2y = y^2 - \frac{2}{3}y - \frac{4}{3}\end{aligned}$$

Minimizamos derivando respecto a y e igualando a cero:

$$\frac{df(2/3, y)}{dy} = 2y - \frac{2}{3} = 0 \implies y = \frac{1}{3} \approx 0.3333$$

El punto resultante al final de la iteración (el primer ciclo de variables) es:

$$x_2 = \left(\frac{2}{3}, \frac{1}{3}\right)^T$$

1.5.3 Apartado 3: Análisis de convergencia y acoplamiento

Ver solución del Apartado 3

Resolución matemática:

Calculemos el óptimo analítico global de la función cuadrática igualando su gradiente a cero:

$$\nabla f(x, y) = \begin{pmatrix} 6x + 2y - 4 \\ 2x + 2y - 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Resolviendo el sistema: * De la segunda ecuación: $2x + 2y = 2 \implies x + y = 1 \implies y = 1 - x$.

* Sustituyendo en la primera:

$$6x + 2(1 - x) - 4 = 0 \implies 4x - 2 = 0 \implies x^* = 0.5$$

* Sustituyendo: $y^* = 0.5$.

El mínimo analítico es $x^* = (0.5, 0.5)^T$. Dado que el punto tras un ciclo completo es $x_2 = (2/3, 1/3)^T \neq x^*$, el método de coordenadas cíclicas **no converge al óptimo de forma directa**.

Esto se debe a que la matriz hessiana:

$$H = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$$

no es una matriz diagonal. El término de acoplamiento cruzado ($2xy$ con coeficiente diferente de cero) deforma las elipses de las curvas de nivel inclinándolas respecto a los ejes de coordenadas. Como el algoritmo solo avanza en direcciones estrictamente paralelas a los ejes coordenados de forma secuencial, se ve obligado a dibujar un camino de “escalones”, ralentizando significativamente la convergencia hacia el óptimo.

1.6 Ejercicio 6: máximo descenso: invarianza ortogonal y trazado

Minimizar la misma función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

partiendo desde $x_0 = (0, 0)^T$ utilizando el método del **Máximo descenso** con búsqueda de tamaño de paso exacta.

1.6.1 Apartado 1: Gradiente y dirección de búsqueda inicial

Ver solución del Apartado 1

Resolución matemática:

1. **Vector gradiente analítico:**

$$\nabla f(x, y) = \begin{pmatrix} 6x + 2y - 4 \\ 2x + 2y - 2 \end{pmatrix}$$

2. **Evaluación en la solución inicial** $x_0 = (0, 0)^T$:

$$\nabla f(x_0) = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

3. **Dirección de máxima bajada** d_0 : La dirección es el gradiente negativo:

$$d_0 = -\nabla f(x_0) = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

1.6.2 Apartado 2: Búsqueda lineal exacta y actualización de puntos

Ver solución del Apartado 2

Resolución matemática:

1. **Trayectoria lineal parametrizada:**

$$x(\alpha) = x_0 + \alpha d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \alpha \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 4\alpha \\ 2\alpha \end{pmatrix}$$

2. **Planteamiento de la función unidimensional $\phi(\alpha)$:** Sustituyendo las variables en la función objetivo:

$$\phi(\alpha) = f(4\alpha, 2\alpha) = 3(4\alpha)^2 + 2(4\alpha)(2\alpha) + (2\alpha)^2 - 4(4\alpha) - 2(2\alpha)$$

$$\phi(\alpha) = 48\alpha^2 + 16\alpha^2 + 4\alpha^2 - 16\alpha - 4\alpha = 68\alpha^2 - 20\alpha$$

3. **Optimización del tamaño de paso:** Minimizamos derivando respecto a α e igualando a cero:

$$\phi'(\alpha) = 136\alpha - 20 = 0 \implies \alpha_0 = \frac{20}{136} = \frac{5}{34} \approx 0.1471$$

4. **Actualización del punto:**

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \frac{5}{34} \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 10/17 \\ 5/17 \end{pmatrix} \approx \begin{pmatrix} 0.5882 \\ 0.2941 \end{pmatrix}$$

1.6.3 Apartado 3: Verificación del Teorema de Ortogonalidad

Ver solución del Apartado 3

Resolución matemática:

1. **Evaluación del gradiente en x_1 :**

$$\nabla f(x_1) = \begin{pmatrix} 6(10/17) + 2(5/17) - 4 \\ 2(10/17) + 2(5/17) - 2 \end{pmatrix} = \begin{pmatrix} \frac{70}{17} - \frac{68}{17} \\ \frac{30}{17} - \frac{34}{17} \end{pmatrix} = \begin{pmatrix} 2/17 \\ -4/17 \end{pmatrix}$$

2. **Siguiente dirección de búsqueda d_1 :**

$$d_1 = -\nabla f(x_1) = \begin{pmatrix} -2/17 \\ 4/17 \end{pmatrix}$$

3. **Cálculo del producto escalar:**

$$d_0^T d_1 = \begin{pmatrix} 4 & 2 \end{pmatrix} \begin{pmatrix} -2/17 \\ 4/17 \end{pmatrix} = 4 \left(-\frac{2}{17} \right) + 2 \left(\frac{4}{17} \right) = -\frac{8}{17} + \frac{8}{17} = 0$$

El resultado demuestra de forma exacta que las direcciones de búsqueda consecutivas son ortogonales, validando experimentalmente el Teorema de la Ortogonalidad Sucesiva de los algoritmos de gradiente con búsqueda exacta.

1.7 Ejercicio 7: Newton multivariante: convergencia cuadrática

Dada la función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

Se pide aplicar el método de **Newton multivariante** libre partiendo del punto de búsqueda inicial $x_0 = (0, 0)^T$:

1.7.1 Apartado 1: Gradiente y Hessiana iniciales

Ver solución del Apartado 1

Resolución matemática:

1. **Gradiente evaluado en x_0 :**

$$\nabla f(x_0) = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

2. **Matriz hessiana (H):** Al tratarse de una función cuadrática, las segundas derivadas parciales son constantes en todo el espacio:

$$H = \nabla^2 f(x) = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$$

1.7.2 Apartado 2: Cálculo de la inversa de la Hessiana

Ver solución del Apartado 2

Resolución matemática:

Para calcular la inversa de la matriz de segundo orden: 1. **Determinante:**

$$\det(H) = 6(2) - 2(2) = 12 - 4 = 8$$

2. **Matriz adjunta transpuesta:** La matriz es simétrica, por lo que:

$$H^{-1} = \frac{1}{\det(H)} \begin{pmatrix} H_{22} & -H_{12} \\ -H_{21} & H_{11} \end{pmatrix} = \frac{1}{8} \begin{pmatrix} 2 & -2 \\ -2 & 6 \end{pmatrix} = \begin{pmatrix} 0.25 & -0.25 \\ -0.25 & 0.75 \end{pmatrix}$$

1.7.3 Apartado 3: Actualización e interpretación física de la convergencia

Ver solución del Apartado 3

Resolución matemática:

1. **Actualización de Newton:**

$$x_1 = x_0 - H^{-1} \nabla f(x_0)$$
$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 0.25 & -0.25 \\ -0.25 & 0.75 \end{pmatrix} \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$
$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 0.25(-4) - 0.25(-2) \\ -0.25(-4) + 0.75(-2) \end{pmatrix} = - \begin{pmatrix} -1 + 0.5 \\ 1 - 1.5 \end{pmatrix} = - \begin{pmatrix} -0.5 \\ -0.5 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$$

2. **Explicación teórica:** El método de Newton multivariante calcula el siguiente iterado optimizando la aproximación cuadrática de segundo orden (Taylor) de la función en el punto actual. Para cualquier función estrictamente cuadrática, esta aproximación de segundo orden es **exacta** en todo el dominio de definición de la función. Como consecuencia directa de esto, la aproximación cuadrática no comete ningún error y el método de Newton localiza el mínimo global exacto en **exactamente una iteración** desde cualquier punto inicial arbitrario.

3. **Verificación de Newton Multivariante en Python (SciPy):**

```
import numpy as np
from scipy.optimize import minimize

def objective(x):
    return 3*x[0]**2 + 2*x[0]*x[1] + x[1]**2 - 4*x[0] - 2*x[1]

# Ejecutar el solver
res = minimize(objective, x0=[0.0, 0.0], method='Newton-CG', jac=lambda x: np.array([6*x[0]+2*x[1]-4, 2*x[0]+2*x[1]-2]))
print("Mínimo numérico alcanzado por Newton:", res.x)
```