

Ejercicios Resueltos de Optimización y Análisis de Redes

Víctor Aceña Gil

Antonio Alonso Ayuso

Índice de Soluciones

Introducción	4
1 Soluciones del Tema 1: Introducción a la investigación operativa	5
1.1 Ejercicio 1: modelado, ciclo de vida e historia	5
1.1.1 1. El circo de Blackett (convoyes navales)	5
1.1.2 2. Propósitos de modelización en una red eléctrica	6
1.1.3 3. Ciclo de vida del modelado en logística de reparto	6
1.2 Ejercicio 2: formulación matemática y clasificación de modelos	6
1.2.1 1. Formulación lineal	7
1.2.2 2. Formulación no lineal	8
1.2.3 3. Verificación computacional mediante Python	8
2 Ejercicios Resueltos del Tema 2: optimización no lineal y métodos numéricos	10
2.1 Ejercicio 1: duopolio de Cournot con costes cuadráticos	10
2.1.1 Apartado 1: Formulación del problema y funciones de reacción	10
2.1.2 Apartado 2: Equilibrio de Cournot-Nash	11
2.1.3 Apartado 3: Análisis de la convexidad del beneficio	12
2.2 Ejercicio 2: caracterización de curvatura y convexidad	13
2.2.1 Apartado 1: Convexidad de $f(x, y) = e^{x^2+y^2}$	13
2.2.2 Apartado 2: Convexidad de $f(x, y) = 2x^2 - 4xy + y^4$	14
2.2.3 Apartado 3: Convexidad de $f(x, y) = -\ln(x) - \ln(y)$	15
2.3 Ejercicio 3: clasificación de puntos estacionarios	15
2.3.1 Apartado 1: Localización de puntos críticos	16
2.3.2 Apartado 2: Clasificación de puntos críticos	16
2.3.3 Apartado 3: Análisis de óptimos globales	17
2.4 Ejercicio 4: trazado de búsqueda áurea y Newton 1D	18
2.4.1 Apartado 1: Paso 1 del método de la sección áurea	18
2.4.2 Apartado 2: Paso 1 del método de Newton 1D	19
2.5 Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales . . .	19
2.5.1 Apartado 1: Búsqueda lineal en la variable x	20
2.5.2 Apartado 2: Búsqueda lineal en la variable y	20
2.5.3 Apartado 3: Análisis de convergencia y acoplamiento	21
2.6 Ejercicio 6: máximo descenso: invarianza ortogonal y trazado	21
2.6.1 Apartado 1: Gradiente y dirección de búsqueda inicial	22
2.6.2 Apartado 2: Búsqueda lineal exacta y actualización de puntos	22

2.6.3	Apartado 3: Verificación del Teorema de Ortogonalidad	23
2.7	Ejercicio 7: Newton multivariante: convergencia cuadrática	23
2.7.1	Apartado 1: Gradiente y Hessiana iniciales	23
2.7.2	Apartado 2: Cálculo de la inversa de la Hessiana	24
2.7.3	Apartado 3: Actualización e interpretación física de la convergencia . .	24
2.7.4	Apartado 4: Newton multivariante en funciones no cuadráticas	25

Introducción

Este cuaderno recopila las **soluciones detalladas** a los ejercicios propuestos para la asignatura **Optimización y Análisis de Redes**.

Cada ejercicio contiene tanto la demostración matemática formal como la implementación de código en Python correspondiente para verificar las soluciones de manera numérica.

1 Soluciones del Tema 1: Introducción a la investigación operativa

1.1 Ejercicio 1: modelado, ciclo de vida e historia

Resolución del Ejercicio 1

1.1.1 1. El circo de Blackett (convoyes navales)

El análisis de Patrick Blackett y su equipo sobre la seguridad de los convoyes navales durante la Segunda Guerra Mundial se basó en una relación geométrica fundamental:

- **Geometría del convoy:**
 - Si agrupamos los barcos mercantes en una sola gran formación (aproximadamente circular), el **área** del convoy (proporcional al número de barcos que transportan mercancías) crece con el cuadrado del radio: $A \propto R^2$.
 - Sin embargo, el **perímetro** del convoy (la zona expuesta que debe ser protegida por barcos de escolta como destructores) crece linealmente con el radio: $P \propto R$.
- **Consecuencia de seguridad:**
 - Al duplicar el área del convoy (doble de barcos mercantes), el perímetro expuesto sólo aumenta por un factor de aproximadamente $\sqrt{2} \approx 1.41$, no al doble.
 - Esto significa que un convoy grande requiere **menos escoltas por barco mercante** que varios convoyes pequeños separados.
 - Además, la probabilidad de que un submarino enemigo avistara un convoy grande era casi la misma que la de avistar un convoy pequeño, por lo que agrupar los barcos redujo drásticamente el número de encuentros y pérdidas.

1.1.2 2. Propósitos de modelización en una red eléctrica

- **Modelo físico/icónico:** Una maqueta a escala de una subestación eléctrica para ensayar la distribución espacial física de los transformadores y cables de alta tensión.
 - **Modelo descriptivo:** Un diagrama unifilar que representa el estado actual de las líneas de transporte y subestaciones, mostrando el flujo de potencia instantáneo en cada línea para responder a: *¿dónde hay sobrecarga hoy?*
 - **Modelo predictivo:** Un modelo de regresión o red neuronal que estima la demanda eléctrica nacional para las próximas 24 horas basándose en la temperatura prevista y el día de la semana.
 - **Modelo prescriptivo:** Un modelo de optimización (despacho económico de energía) que determina qué centrales generadoras deben encenderse y a qué potencia operar mañana para satisfacer la demanda prevista al menor coste operativo total.
-

1.1.3 3. Ciclo de vida del modelado en logística de reparto

1. **Observación:** Reunirse con los gestores de tráfico, recopilar datos GPS de rutas históricas, consumos medios de combustible por vehículo y coordenadas de los puntos de entrega del supermercado.
 2. **Formulación:** Definir las variables de decisión (si el camión k visita el cliente j después de i), plantear la función objetivo (minimizar kilómetros o consumo equivalente de combustible) y escribir las restricciones (horarios de entrega, capacidad de carga máxima del camión, tiempos de descanso del conductor).
 3. **Validación:** Resolver el modelo para un subconjunto de rutas reales conocidas y contrastar el plan del algoritmo frente al plan histórico del supermercado para comprobar si la solución es realista y si el ahorro estimado es factible.
 4. **Implementación:** Integrar el software de optimización de rutas en la aplicación móvil de los repartidores y en el ERP del centro logístico, formando al personal de planificación.
-

1.2 Ejercicio 2: formulación matemática y clasificación de modelos

Resolución del Ejercicio 2

1.2.1 1. Formulación lineal

Definimos las variables de decisión:

- x_1 : Hectolitros (hl) de cerveza IPA a producir.
- x_2 : Hectolitros (hl) de cerveza Stout a producir.

Función objetivo: Maximizar el beneficio neto total (en €):

$$\max_{x_1, x_2} Z = 150x_1 + 120x_2$$

Restricciones:

1. Límite de Malta (kg):

$$15x_1 + 20x_2 \leq 300$$

2. Límite de Lúpulo (kg):

$$4x_1 + 2x_2 \leq 50$$

3. Límite de tiempo en fermentación (días):

$$2x_1 + 3x_2 \leq 45$$

4. No negatividad:

$$x_1, x_2 \geq 0$$

Clasificación del modelo:

- **Linealidad:** Modelo de Programación Lineal (LP), ya que tanto la función objetivo como todas las restricciones son funciones lineales.
 - **Dominio:** Programación continua (o real) en $\mathbb{R}^2$ (asumiendo que los hectolitros se pueden fraccionar).
 - **Determinismo:** Modelo determinista (todos los parámetros son conocidos y no estocásticos).
-

1.2.2 2. Formulación no lineal

Con la nueva política de precios sensibles a la cantidad de producción:

- Beneficio unitario de IPA: $150 - 2x_1$ €/hl.
- Beneficio unitario de Stout: $120 - 3x_2$ €/hl.

Nueva función objetivo: Maximizar el beneficio total resultante de multiplicar la cantidad por el precio unitario:

$$\max_{x_1, x_2} Z(x_1, x_2) = x_1(150 - 2x_1) + x_2(120 - 3x_2) = -2x_1^2 + 150x_1 - 3x_2^2 + 120x_2$$

Restricciones: Las restricciones de recursos físicos permanecen inalteradas:

$$\begin{aligned} 15x_1 + 20x_2 &\leq 300 \\ 4x_1 + 2x_2 &\leq 50 \\ 2x_1 + 3x_2 &\leq 45 \\ x_1, x_2 &\geq 0 \end{aligned}$$

Clasificación del modelo:

- **Linealidad:** Modelo de Programación No Lineal (NLP), debido a que la función objetivo contiene términos cuadráticos (es cóncava cuadrática).
 - **Dominio:** Continuo.
 - **Determinismo:** Determinista.
-

1.2.3 3. Verificación computacional mediante Python

Podemos resolver el modelo cuadrático utilizando `scipy.optimize` en Python:

```
import numpy as np
from scipy.optimize import minimize

# Definimos la función objetivo a minimizar (negativo del beneficio para maximizar)
def objective(x):
    return -(-2 * x[0]**2 + 150 * x[0] - 3 * x[1]**2 + 120 * x[1])

# Definimos las restricciones g_i(x) <= 0
# 15*x1 + 20*x2 <= 300 --> 15*x1 + 20*x2 - 300 <= 0
```



```

# 4*x1 + 2*x2 <= 50      --> 4*x1 + 2*x2 - 50 <= 0
# 2*x1 + 3*x2 <= 45      --> 2*x1 + 3*x2 - 45 <= 0
constraints = [
    {'type': 'ineq', 'fun': lambda x: 300 - (15 * x[0] + 20 * x[1])},
    {'type': 'ineq', 'fun': lambda x: 50 - (4 * x[0] + 2 * x[1])},
    {'type': 'ineq', 'fun': lambda x: 45 - (2 * x[0] + 3 * x[1])}
]

# Límites de no negatividad
bounds = [(0, None), (0, None)]

# Punto de inicio
x0 = [0, 0]

# Resolver
res = minimize(objective, x0, method='SLSQP', bounds=bounds, constraints=constraints)

print("--- SOLUCIÓN DE VERIFICACIÓN ---")
print(f"Estado de la optimización: {res.message}")
print(f"Cantidad IPA (hl) óptima x1: {round(res.x[0], 4)} hl")
print(f"Cantidad Stout (hl) óptima x2: {round(res.x[1], 4)} hl")
print(f"Beneficio máximo total: {round(-res.fun, 2)} €")

```

--- SOLUCIÓN DE VERIFICACIÓN ---

Estado de la optimización: Optimization terminated successfully
 Cantidad IPA (hl) óptima x1: 8.0 hl
 Cantidad Stout (hl) óptima x2: 9.0 hl
 Beneficio máximo total: 1909.0 €

2 Ejercicios Resueltos del Tema 2: optimización no lineal y métodos numéricos

2.1 Ejercicio 1: duopolio de Cournot con costes cuadráticos

Dos empresas competidoras, Empresa 1 y Empresa 2, producen un bien de consumo homogéneo. La función de demanda inversa de mercado viene dada por:

$$P(Q) = 20 - Q$$

donde $Q = Q_1 + Q_2$ es la producción total acumulada en el mercado. Las funciones de coste total de cada empresa son cuadráticas y se definen como:

$$C_1(Q_1) = 2Q_1 + \frac{1}{2}Q_1^2 \quad \text{y} \quad C_2(Q_2) = 3Q_2 + Q_2^2$$

Las producciones están limitadas físicamente por capacidades máximas: $Q_1 \leq 8$ y $Q_2 \leq 6$, y no pueden ser negativas.

2.1.1 Apartado 1: Formulación del problema y funciones de reacción

Formular el problema de optimización individual de cada empresa para maximizar sus beneficios, determinando sus funciones de reacción o mejor respuesta $Q_1^*(Q_2)$ y $Q_2^*(Q_1)$.

Ver solución del Apartado 1

Resolución matemática:

1. **Empresa 1:** El beneficio B_1 se define como la diferencia entre los ingresos y el coste total:

$$B_1(Q_1, Q_2) = P(Q_1 + Q_2) \cdot Q_1 - C_1(Q_1)$$
$$B_1(Q_1, Q_2) = (20 - Q_1 - Q_2)Q_1 - \left(2Q_1 + \frac{1}{2}Q_1^2\right) = 18Q_1 - \frac{3}{2}Q_1^2 - Q_1Q_2$$

Para maximizar, derivamos respecto a Q_1 e igualamos a cero (FONC):

$$\frac{\partial B_1}{\partial Q_1} = 18 - 3Q_1 - Q_2 = 0 \implies 3Q_1 = 18 - Q_2 \implies Q_1^*(Q_2) = 6 - \frac{Q_2}{3}$$

Como $Q_2 \geq 0$, la función de mejor respuesta de la Empresa 1 satisface $Q_1^*(Q_2) \leq 6 \leq 8$, por lo que la restricción de capacidad máxima $Q_1 \leq 8$ no se satura y se cumple de forma inactiva.

2. **Empresa 2:** Su beneficio B_2 viene dado por:

$$B_2(Q_1, Q_2) = P(Q_1 + Q_2) \cdot Q_2 - C_2(Q_2)$$

$$B_2(Q_1, Q_2) = (20 - Q_1 - Q_2)Q_2 - (3Q_2 + Q_2^2) = 17Q_2 - 2Q_2^2 - Q_1Q_2$$

Derivando respecto a Q_2 e igualando a cero (FONC):

$$\frac{\partial B_2}{\partial Q_2} = 17 - 4Q_2 - Q_1 = 0 \implies 4Q_2 = 17 - Q_1 \implies Q_2^*(Q_1) = 4.25 - \frac{Q_1}{4}$$

De nuevo, dado que $Q_1 \geq 0$, se cumple que $Q_2^*(Q_1) \leq 4.25 \leq 6$, por lo que la restricción $Q_2 \leq 6$ tampoco se satura.

2.1.2 Apartado 2: Equilibrio de Cournot-Nash

Calcular analíticamente el equilibrio de Cournot-Nash del mercado (el punto donde ambas decisiones son óptimas simultáneamente).

Ver solución del Apartado 2

Resolución matemática:

El equilibrio de Cournot-Nash se encuentra resolviendo el sistema lineal de ecuaciones formado por las dos funciones de reacción:

$$\begin{cases} 3Q_1 + Q_2 = 18 \\ Q_1 + 4Q_2 = 17 \end{cases}$$

Despejando y resolviendo el sistema:

- De la segunda ecuación: $Q_1 = 17 - 4Q_2$.
- Sustituyendo en la primera:

$$3(17 - 4Q_2) + Q_2 = 18 \implies 51 - 12Q_2 + Q_2 = 18 \implies 11Q_2 = 33 \implies Q_2^* = 3$$

- Calculando Q_1 :

$$Q_1^* = 17 - 4(3) = 5$$

El equilibrio de Cournot-Nash es:

$$(Q_1^*, Q_2^*) = (5, 3)$$

El precio de mercado resultante es:

$$P^* = 20 - (5 + 3) = 12 \text{ u.m.}$$

Los beneficios en el equilibrio de Nash de cada empresa son:

- Empresa 1: $B_1^* = 12 \cdot 5 - 2 \cdot 5 - 0.5 \cdot 5^2 = 60 - 10 - 12.5 = 37.5 \text{ u.m.}$
- Empresa 2: $B_2^* = 12 \cdot 3 - 3 \cdot 3 - 3^2 = 36 - 9 - 9 = 18 \text{ u.m.}$

2.1.3 Apartado 3: Análisis de la convexidad del beneficio

Analizar la convexidad de las funciones de beneficio de cada empresa y discutir si el problema de optimización resultante es convexo.

Ver solución del Apartado 3

Resolución matemática:

1. **Convexidad del problema individual:** El problema de cada empresa es un problema de maximización de beneficios. En el contexto de optimización, un problema de maximización es convexo si la función objetivo es cóncava y el conjunto factible es convexo (lo cual se cumple ya que los intervalos de producción $[0, 8]$ y $[0, 6]$ son conjuntos convexos). Analicemos la segunda derivada de las funciones de beneficio individuales:
 - Empresa 1: $\frac{\partial^2 B_1}{\partial Q_1^2} = -3 < 0$. Al ser la segunda derivada estrictamente negativa para cualquier punto, B_1 es estrictamente cóncava respecto a Q_1 .
 - Empresa 2: $\frac{\partial^2 B_2}{\partial Q_2^2} = -4 < 0$. Por tanto, B_2 es estrictamente cóncava respecto a Q_2 .
 - **Conclusión:** Ambos problemas de optimización individuales son estrictamente convexos.
2. **Verificación del equilibrio en Python:** Podemos validar el cálculo y la concavidad de forma simbólica usando el siguiente script en Python:

```
import sympy as sp

Q1, Q2 = sp.symbols('Q1 Q2')
B1 = (20 - Q1 - Q2)*Q1 - 2*Q1 - 0.5*Q1**2
B2 = (20 - Q1 - Q2)*Q2 - 3*Q2 - Q2**2
```

```
# Derivadas parciales de primer orden (FONC)
dB1 = sp.diff(B1, Q1)
dB2 = sp.diff(B2, Q2)

# Resolver sistema para el equilibrio de Nash
eq = sp.solve([dB1, dB2], (Q1, Q2))
print("Equilibrio de Nash (Q1, Q2):", eq)

# Verificar segundas derivadas (Concavidad)
d2B1 = sp.diff(B1, Q1, 2)
d2B2 = sp.diff(B2, Q2, 2)
print("Segunda derivada B1:", d2B1)
print("Segunda derivada B2:", d2B2)
```

```
Equilibrio de Nash (Q1, Q2): {Q1: 5.000000000000000, Q2: 3.000000000000000}
Segunda derivada B1: -3.000000000000000
Segunda derivada B2: -4
```

2.2 Ejercicio 2: caracterización de curvatura y convexidad

Analizar la convexidad de las siguientes funciones en sus respectivos dominios utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores:

2.2.1 Apartado 1: Convexidad de $f(x, y) = e^{x^2+y^2}$

Ver solución del Apartado 1

Resolución matemática:

1. **Gradiente de primer orden:**

$$\frac{\partial f}{\partial x} = 2xe^{x^2+y^2} \quad \text{y} \quad \frac{\partial f}{\partial y} = 2ye^{x^2+y^2}$$

2. **Matriz hessiana (H):** Calculando las segundas derivadas:

$$\frac{\partial^2 f}{\partial x^2} = (2 + 4x^2)e^{x^2+y^2} \quad \frac{\partial^2 f}{\partial y^2} = (2 + 4y^2)e^{x^2+y^2}$$

$$\frac{\partial^2 f}{\partial x \partial y} = 4xye^{x^2+y^2}$$

Por lo tanto:

$$H(x, y) = e^{x^2+y^2} \begin{pmatrix} 2 + 4x^2 & 4xy \\ 4xy & 2 + 4y^2 \end{pmatrix}$$

3. Menores principales:

- $M_1 = e^{x^2+y^2}(2 + 4x^2) > 0$ (ya que la función exponencial es siempre estrictamente positiva y $2 + 4x^2 \geq 2$).
- $M_2 = \det(H) = e^{2(x^2+y^2)} [(2 + 4x^2)(2 + 4y^2) - 16x^2y^2]$

$$M_2 = e^{2(x^2+y^2)} [4 + 8x^2 + 8y^2 + 16x^2y^2 - 16x^2y^2] = e^{2(x^2+y^2)} [4 + 8x^2 + 8y^2] > 0$$

- **Conclusión:** Dado que todos los menores principales son estrictamente positivos para cualquier $(x, y) \in \mathbb{R}^2$, la matriz hessiana es definida positiva ($H \succ 0$). Por tanto, la función es **estrictamente convexa** en todo su dominio $\mathbb{R}^2$.

2.2.2 Apartado 2: Convexidad de $f(x, y) = 2x^2 - 4xy + y^4$

Ver solución del Apartado 2

Resolución matemática:

1. Gradiente:

$$\frac{\partial f}{\partial x} = 4x - 4y \quad \text{y} \quad \frac{\partial f}{\partial y} = -4x + 4y^3$$

2. Matriz hessiana (H):

$$H(x, y) = \begin{pmatrix} 4 & -4 \\ -4 & 12y^2 \end{pmatrix}$$

3. Menores principales:

- $M_1 = 4 > 0$.
- $M_2 = \det(H) = 48y^2 - 16 = 16(3y^2 - 1)$.
- **Análisis:** Para que la función sea convexa en su dominio, la hessiana debe ser semidefinida positiva para todo $(x, y) \in \mathbb{R}^2$. Sin embargo, vemos que M_2 depende del valor de la variable y :
- Si $3y^2 - 1 < 0 \implies |y| < \frac{1}{\sqrt{3}}$, entonces $M_2 < 0$. Al ser el determinante negativo, la matriz es indefinida.
- **Conclusión:** La función **no es convexa en todo el dominio** $\mathbb{R}^2$ (únicamente exhibe convexidad local en el espacio donde se satisface $|y| \geq \frac{1}{\sqrt{3}}$).

2.2.3 Apartado 3: Convexidad de $f(x, y) = -\ln(x) - \ln(y)$

Ver solución del Apartado 3

Resolución matemática:

1. **Gradiente:**

$$\frac{\partial f}{\partial x} = -\frac{1}{x} \quad y \quad \frac{\partial f}{\partial y} = -\frac{1}{y}$$

2. **Matriz hessiana (H):**

$$H(x, y) = \begin{pmatrix} 1/x^2 & 0 \\ 0 & 1/y^2 \end{pmatrix}$$

3. **Menores principales:** En el dominio $\mathbb{R}_{++}^2$ se tiene que:

- $M_1 = \frac{1}{x^2} > 0$ (ya que $x > 0$).
- $M_2 = \det(H) = \frac{1}{x^2 y^2} > 0$ (ya que $x, y > 0$).
- **Conclusión:** Al ser los menores principales estrictamente positivos en todo el dominio de definición de la función, la hessiana es definida positiva ($H \succ 0$) y la función es **estrictamente convexa** en $\mathbb{R}_{++}^2$.

4. **Validación en Python (SymPy):**

```
import sympy as sp

x, y = sp.symbols('x y', real=True)

# Caso 2: f(x, y) = 2x^2 - 4xy + y^4
f2 = 2*x**2 - 4*x*y + y**4
H2 = sp.hessian(f2, (x, y))
print("Hessiana de f2:\n", H2)
print("Determinante de H2:", H2.det())
```

Hessiana de f2:

Matrix([[4, -4], [-4, 12*y**2]])

Determinante de H2: 48*y**2 - 16

2.3 Ejercicio 3: clasificación de puntos estacionarios

Considerar la siguiente función real de dos variables:

$$f(x, y) = x^3 + y^3 - 3x - 12y + 20$$

2.3.1 Apartado 1: Localización de puntos críticos

Encontrar todos los puntos críticos o estacionarios de la función aplicando las condiciones de primer orden (FONC).

Ver solución del Apartado 1

Resolución matemática:

Las condiciones necesarias de primer orden (FONC) exigen que el vector gradiente sea nulo:

$$\nabla f(x, y) = \begin{pmatrix} 3x^2 - 3 \\ 3y^2 - 12 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Esto genera un sistema de dos ecuaciones independientes:

1. $3x^2 - 3 = 0 \implies x^2 = 1 \implies x = \pm 1$.
2. $3y^2 - 12 = 0 \implies y^2 = 4 \implies y = \pm 2$.

Combinando todas las soluciones posibles, obtenemos **cuatro puntos críticos**:

- $P_1 = (1, 2)$
- $P_2 = (1, -2)$
- $P_3 = (-1, 2)$
- $P_4 = (-1, -2)$

2.3.2 Apartado 2: Clasificación de puntos críticos

Clasificar cada uno de los puntos estacionarios hallados utilizando el criterio de la matriz hessiana y las condiciones de segundo orden (SOSC).

Ver solución del Apartado 2

Resolución matemática:

Calculamos la matriz hessiana general para la función:

$$H(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 6y \end{pmatrix}$$

Al ser una matriz diagonal, sus autovalores son directamente los elementos de la diagonal principal: $\lambda_1 = 6x$ y $\lambda_2 = 6y$. Evaluamos cada uno de los cuatro puntos:

1. **Punto** $P_1 = (1, 2)$:

$$H(1, 2) = \begin{pmatrix} 6 & 0 \\ 0 & 12 \end{pmatrix} \Rightarrow \lambda_1 = 6 > 0, \quad \lambda_2 = 12 > 0$$

Hessiana definida positiva ($H \succ 0$). Por tanto, P_1 es un **mínimo local estricto**. Valor de la función: $f(1, 2) = 1^3 + 2^3 - 3(1) - 12(2) + 20 = 2$.

2. **Punto** $P_2 = (1, -2)$:

$$H(1, -2) = \begin{pmatrix} 6 & 0 \\ 0 & -12 \end{pmatrix} \Rightarrow \lambda_1 = 6 > 0, \quad \lambda_2 = -12 < 0$$

Hessiana indefinida (autovalores de distinto signo). Por tanto, P_2 es un **punto de silla**. Valor de la función: $f(1, -2) = 1^3 + (-2)^3 - 3(1) - 12(-2) + 20 = 34$.

3. **Punto** $P_3 = (-1, 2)$:

$$H(-1, 2) = \begin{pmatrix} -6 & 0 \\ 0 & 12 \end{pmatrix} \Rightarrow \lambda_1 = -6 < 0, \quad \lambda_2 = 12 > 0$$

Hessiana indefinida. Por tanto, P_3 es un **punto de silla**. Valor de la función: $f(-1, 2) = (-1)^3 + 2^3 - 3(-1) - 12(2) + 20 = 6$.

4. **Punto** $P_4 = (-1, -2)$:

$$H(-1, -2) = \begin{pmatrix} -6 & 0 \\ 0 & -12 \end{pmatrix} \Rightarrow \lambda_1 = -6 < 0, \quad \lambda_2 = -12 < 0$$

Hessiana definida negativa ($H \prec 0$). Por tanto, P_4 es un **máximo local estricto**. Valor de la función: $f(-1, -2) = (-1)^3 + (-2)^3 - 3(-1) - 12(-2) + 20 = 38$.

2.3.3 Apartado 3: Análisis de óptimos globales

Determinar razonadamente si la función posee algún mínimo global o máximo global sobre todo el dominio $\mathbb{R}^2$.

Ver solución del Apartado 3

Resolución matemática:

La función **no posee óptimos globales** sobre $\mathbb{R}^2$ por falta de acotación:

- Si fijamos $y = 0$ y hacemos tender $x \rightarrow +\infty$: $\lim_{x \rightarrow +\infty} f(x, 0) = \lim_{x \rightarrow +\infty} (x^3 - 3x + 20) = +\infty$.
- Si fijamos $y = 0$ y hacemos tender $x \rightarrow -\infty$: $\lim_{x \rightarrow -\infty} f(x, 0) = \lim_{x \rightarrow -\infty} (x^3 - 3x + 20) = -\infty$.

Dado que la función no está acotada superior ni inferiormente en $\mathbb{R}^2$, los mínimos y máximos locales hallados no pueden extender su validez de manera global.

2.4 Ejercicio 4: trazado de búsqueda áurea y Newton 1D

Se desea encontrar el mínimo global de la función real:

$$f(x) = x \ln(x) - 1.5x$$

en el intervalo acotado $[1, 3]$. Se sabe que el mínimo analítico exacto se encuentra en $x^* = e^{0.5} \approx 1.6487$.

2.4.1 Apartado 1: Paso 1 del método de la sección áurea

Ver solución del Apartado 1

Resolución matemática:

1. **Amplitud de búsqueda inicial:** El intervalo inicial es $[a_0, b_0] = [1, 3]$. Su amplitud es $b_0 - a_0 = 2.0$.

2. **Amplitud de reducción I_1 :** Utilizando la razón áurea $\alpha \approx 1.61803$:

$$I_1 = \frac{b_0 - a_0}{\alpha} = \frac{2.0}{1.61803} \approx 1.2361$$

3. **Puntos de evaluación iniciales:**

$$\lambda_0 = b_0 - I_1 = 3 - 1.2361 = 1.7639$$

$$\mu_0 = a_0 + I_1 = 1 + 1.2361 = 2.2361$$

4. **Evaluación de la función:**

- $f(\lambda_0) = f(1.7639) = 1.7639 \ln(1.7639) - 1.5(1.7639) \approx -1.6449$
- $f(\mu_0) = f(2.2361) = 2.2361 \ln(2.2361) - 1.5(2.2361) \approx -1.5548$

5. **Descarte de intervalos:** Como $f(\lambda_0) < f(\mu_0)$ (es decir, $-1.6449 < -1.5548$), el mínimo no puede encontrarse en el subintervalo $[\mu_0, b_0]$. Por lo tanto, descartamos la porción derecha del dominio. El **nuevo intervalo** para la siguiente iteración es:

$$[a_1, b_1] = [a_0, \mu_0] = [1.0, 2.2361]$$

Su amplitud es 1.2361, que resulta mayor que la tolerancia $\epsilon = 0.5$, por lo que el algoritmo continuaría.

2.4.2 Apartado 2: Paso 1 del método de Newton 1D

Ver solución del Apartado 2

Resolución matemática:

1. Ecuaciones de las derivadas:

- Función: $f(x) = x \ln(x) - 1.5x$
- Primera derivada: $f'(x) = \ln(x) + x \left(\frac{1}{x}\right) - 1.5 = \ln(x) - 0.5$
- Segunda derivada: $f''(x) = \frac{1}{x}$

2. Evaluación en el punto inicial $x_0 = 1.0$:

- $f'(1.0) = \ln(1.0) - 0.5 = -0.5$
- $f''(1.0) = \frac{1}{1.0} = 1.0$

3. Actualización de Newton:

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.0 - \frac{-0.5}{1.0} = 1.5$$

La aproximación $x_1 = 1.5$ se sitúa notablemente cerca del óptimo analítico exacto $x^* \approx 1.6487$ en un único paso debido a que la función objetivo presenta una curvatura muy bien aproximada cuadráticamente en el entorno de x_0 .

2.5 Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales

Dada la función cuadrática de dos variables con acoplamiento:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

2.5.1 Apartado 1: Búsqueda lineal en la variable x

Ver solución del Apartado 1

Resolución matemática:

Partimos de $x_0 = (0, 0)^T$. Optimizamos respecto a la primera dirección coordenada $e_1 = (1, 0)^T$ fijando la variable $y = 0$:

$$f(x, 0) = 3x^2 + 2x(0) + (0)^2 - 4x - 2(0) = 3x^2 - 4x$$

Minimizamos esta función de una sola variable derivando e igualando a cero:

$$\frac{df(x, 0)}{dx} = 6x - 4 = 0 \implies x = \frac{4}{6} = \frac{2}{3} \approx 0.6667$$

El punto resultante al término de la primera búsqueda lineal es:

$$x_1 = \left(\frac{2}{3}, 0\right)^T$$

2.5.2 Apartado 2: Búsqueda lineal en la variable y

Ver solución del Apartado 2

Resolución matemática:

Fijando $x = x_1 = 2/3$, optimizamos ahora respecto a la segunda dirección coordenada $e_2 = (0, 1)^T$:

$$f(2/3, y) = 3\left(\frac{2}{3}\right)^2 + 2\left(\frac{2}{3}\right)y + y^2 - 4\left(\frac{2}{3}\right) - 2y$$

$$f(2/3, y) = \frac{4}{3} + \frac{4}{3}y + y^2 - \frac{8}{3} - 2y = y^2 - \frac{2}{3}y - \frac{4}{3}$$

Minimizamos derivando respecto a y e igualando a cero:

$$\frac{df(2/3, y)}{dy} = 2y - \frac{2}{3} = 0 \implies y = \frac{1}{3} \approx 0.3333$$

El punto resultante al final de la iteración (el primer ciclo de variables) es:

$$x_2 = \left(\frac{2}{3}, \frac{1}{3}\right)^T$$

2.5.3 Apartado 3: Análisis de convergencia y acoplamiento

Ver solución del Apartado 3

Resolución matemática:

Calculemos el óptimo analítico global de la función cuadrática igualando su gradiente a cero:

$$\nabla f(x, y) = \begin{pmatrix} 6x + 2y - 4 \\ 2x + 2y - 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Resolviendo el sistema:

- De la segunda ecuación: $2x + 2y = 2 \implies x + y = 1 \implies y = 1 - x$.
- Sustituyendo en la primera:

$$6x + 2(1 - x) - 4 = 0 \implies 4x - 2 = 0 \implies x^* = 0.5$$

- Sustituyendo: $y^* = 0.5$.

El mínimo analítico es $x^* = (0.5, 0.5)^T$. Dado que el punto tras un ciclo completo es $x_2 = (2/3, 1/3)^T \neq x^*$, el método de coordenadas cíclicas **no converge al óptimo de forma directa**.

Esto se debe a que la matriz hessiana:

$$H = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$$

no es una matriz diagonal. El término de acoplamiento cruzado ($2xy$ con coeficiente diferente de cero) deforma las elipses de las curvas de nivel inclinándolas respecto a los ejes de coordenadas. Como el algoritmo solo avanza en direcciones estrictamente paralelas a los ejes coordenados de forma secuencial, se ve obligado a dibujar un camino de “escalones”, ralentizando significativamente la convergencia hacia el óptimo.

2.6 Ejercicio 6: máximo descenso: invarianza ortogonal y trazado

Minimizar la misma función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

partiendo desde $x_0 = (0, 0)^T$ utilizando el método del **Máximo descenso** con búsqueda de tamaño de paso exacta.

2.6.1 Apartado 1: Gradiente y dirección de búsqueda inicial

Ver solución del Apartado 1

Resolución matemática:

1. **Vector gradiente analítico:**

$$\nabla f(x, y) = \begin{pmatrix} 6x + 2y - 4 \\ 2x + 2y - 2 \end{pmatrix}$$

2. **Evaluación en la solución inicial** $x_0 = (0, 0)^T$:

$$\nabla f(x_0) = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

3. **Dirección de máxima bajada** d_0 : La dirección es el gradiente negativo:

$$d_0 = -\nabla f(x_0) = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

2.6.2 Apartado 2: Búsqueda lineal exacta y actualización de puntos

Ver solución del Apartado 2

Resolución matemática:

1. **Trayectoria lineal parametrizada:**

$$x(\alpha) = x_0 + \alpha d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \alpha \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 4\alpha \\ 2\alpha \end{pmatrix}$$

2. **Planteamiento de la función unidimensional** $\phi(\alpha)$: Sustituyendo las variables en la función objetivo:

$$\phi(\alpha) = f(4\alpha, 2\alpha) = 3(4\alpha)^2 + 2(4\alpha)(2\alpha) + (2\alpha)^2 - 4(4\alpha) - 2(2\alpha)$$

$$\phi(\alpha) = 48\alpha^2 + 16\alpha^2 + 4\alpha^2 - 16\alpha - 4\alpha = 68\alpha^2 - 20\alpha$$

3. **Optimización del tamaño de paso:** Minimizamos derivando respecto a α e igualando a cero:

$$\phi'(\alpha) = 136\alpha - 20 = 0 \implies \alpha_0 = \frac{20}{136} = \frac{5}{34} \approx 0.1471$$

4. **Actualización del punto:**

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \frac{5}{34} \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 10/17 \\ 5/17 \end{pmatrix} \approx \begin{pmatrix} 0.5882 \\ 0.2941 \end{pmatrix}$$

2.6.3 Apartado 3: Verificación del Teorema de Ortogonalidad

Ver solución del Apartado 3

Resolución matemática:

1. **Evaluación del gradiente en x_1 :**

$$\nabla f(x_1) = \begin{pmatrix} 6(10/17) + 2(5/17) - 4 \\ 2(10/17) + 2(5/17) - 2 \end{pmatrix} = \begin{pmatrix} \frac{70}{17} - \frac{68}{17} \\ \frac{30}{17} - \frac{34}{17} \end{pmatrix} = \begin{pmatrix} 2/17 \\ -4/17 \end{pmatrix}$$

2. **Siguiente dirección de búsqueda d_1 :**

$$d_1 = -\nabla f(x_1) = \begin{pmatrix} -2/17 \\ 4/17 \end{pmatrix}$$

3. **Cálculo del producto escalar:**

$$d_0^T d_1 = \begin{pmatrix} 4 & 2 \end{pmatrix} \begin{pmatrix} -2/17 \\ 4/17 \end{pmatrix} = 4 \left(-\frac{2}{17} \right) + 2 \left(\frac{4}{17} \right) = -\frac{8}{17} + \frac{8}{17} = 0$$

El resultado demuestra de forma exacta que las direcciones de búsqueda consecutivas son ortogonales, validando experimentalmente el Teorema de la Ortogonalidad Sucesiva de los algoritmos de gradiente con búsqueda exacta.

2.7 Ejercicio 7: Newton multivariante: convergencia cuadrática

Dada la función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

Se pide aplicar el método de **Newton multivariante** libre partiendo del punto de búsqueda inicial $x_0 = (0, 0)^T$:

2.7.1 Apartado 1: Gradiente y Hessiana iniciales

Ver solución del Apartado 1

Resolución matemática:

1. **Gradiente evaluado en x_0 :**

$$\nabla f(x_0) = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

2. **Matriz hessiana (H):** Al tratarse de una función cuadrática, las segundas derivadas parciales son constantes en todo el espacio:

$$H = \nabla^2 f(x) = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$$

2.7.2 Apartado 2: Cálculo de la inversa de la Hessiana

Ver solución del Apartado 2

Resolución matemática:

Para calcular la inversa de la matriz de segundo orden:

1. **Determinante:**

$$\det(H) = 6(2) - 2(2) = 12 - 4 = 8$$

2. **Matriz adjunta transpuesta:** La matriz es simétrica, por lo que:

$$H^{-1} = \frac{1}{\det(H)} \begin{pmatrix} H_{22} & -H_{12} \\ -H_{21} & H_{11} \end{pmatrix} = \frac{1}{8} \begin{pmatrix} 2 & -2 \\ -2 & 6 \end{pmatrix} = \begin{pmatrix} 0.25 & -0.25 \\ -0.25 & 0.75 \end{pmatrix}$$

2.7.3 Apartado 3: Actualización e interpretación física de la convergencia

Ver solución del Apartado 3

Resolución matemática:

1. **Actualización de Newton:**

$$x_1 = x_0 - H^{-1} \nabla f(x_0)$$

$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 0.25 & -0.25 \\ -0.25 & 0.75 \end{pmatrix} \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 0.25(-4) - 0.25(-2) \\ -0.25(-4) + 0.75(-2) \end{pmatrix} = - \begin{pmatrix} -1 + 0.5 \\ 1 - 1.5 \end{pmatrix} = - \begin{pmatrix} -0.5 \\ -0.5 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$$

2. **Explicación teórica:** El método de Newton multivariante calcula el siguiente iterado optimizando la aproximación cuadrática de segundo orden (Taylor) de la función en el punto actual. Para cualquier función estrictamente cuadrática, esta aproximación de segundo orden es **exacta** en todo el dominio de definición de la función. Como consecuencia directa de esto, la aproximación cuadrática no comete ningún error y el método de Newton localiza el mínimo global exacto en **exactamente una iteración** desde cualquier punto inicial arbitrario.
3. **Verificación de Newton Multivariante en Python (SciPy):**

```
import numpy as np
from scipy.optimize import minimize

def objective(x):
    return 3*x[0]**2 + 2*x[0]*x[1] + x[1]**2 - 4*x[0] - 2*x[1]

# Ejecutar el solver
res = minimize(objective, x0=[0.0, 0.0], method='Newton-CG', jac=lambda x: np.array([6*x[0]+2*x[1]-4, 2*x[0]+2*x[1]-2]))
print("Mínimo numérico alcanzado por Newton:", res.x)
```

Mínimo numérico alcanzado por Newton: [0.5 0.5]

2.7.4 Apartado 4: Newton multivariante en funciones no cuadráticas

Considere ahora una función no cuadrática dada por:

$$g(x, y) = e^x - x + y^2$$

Partiendo del punto inicial $x_0 = (1, 1)^T$, calcule la primera iteración de Newton multivariante x_1 . Determine si x_1 es el óptimo analítico de la función y discuta cómo difiere la convergencia del método en funciones no cuadráticas.

Ver solución del Apartado 4

Resolución matemática:

1. **Cálculo del gradiente de $g(x, y)$:**

$$\nabla g(x, y) = \begin{pmatrix} e^x - 1 \\ 2y \end{pmatrix}$$

Evaluando en $x_0 = (1, 1)^T$:

$$\nabla g(1, 1) = \begin{pmatrix} e^1 - 1 \\ 2(1) \end{pmatrix} = \begin{pmatrix} e - 1 \\ 2 \end{pmatrix} \approx \begin{pmatrix} 1.7183 \\ 2 \end{pmatrix}$$

2. **Cálculo de la matriz hessiana de $g(x, y)$:**

$$H(x, y) = \nabla^2 g(x, y) = \begin{pmatrix} e^x & 0 \\ 0 & 2 \end{pmatrix}$$

Evaluando en $x_0 = (1, 1)^T$:

$$H(1, 1) = \begin{pmatrix} e & 0 \\ 0 & 2 \end{pmatrix} \approx \begin{pmatrix} 2.7183 & 0 \\ 0 & 2 \end{pmatrix}$$

3. **Cálculo de la matriz inversa de la hessiana:** Al ser una matriz diagonal, su inversa se obtiene directamente invirtiendo los elementos de la diagonal principal:

$$H^{-1}(1, 1) = \begin{pmatrix} e^{-1} & 0 \\ 0 & 0.5 \end{pmatrix} \approx \begin{pmatrix} 0.3679 & 0 \\ 0 & 0.5 \end{pmatrix}$$

4. **Actualización de Newton:**

$$x_1 = x_0 - H^{-1} \nabla g(x_0)$$

$$x_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} e^{-1} & 0 \\ 0 & 0.5 \end{pmatrix} \begin{pmatrix} e - 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} e^{-1}(e - 1) \\ 0.5(2) \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 - e^{-1} \\ 1 \end{pmatrix} = \begin{pmatrix} e^{-1} \\ 0 \end{pmatrix} \approx \begin{pmatrix} 0.3679 \\ 0 \end{pmatrix}$$

5. **Análisis del óptimo analítico:** El gradiente de $g(x, y)$ es nulo si:

$$\nabla g(x, y) = \begin{pmatrix} e^x - 1 \\ 2y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies e^x = 1 \implies x^* = 0, \quad 2y = 0 \implies y^* = 0$$

El mínimo analítico global exacto se encuentra en $x^* = (0, 0)^T$. Dado que $x_1 = (e^{-1}, 0)^T \approx (0.3679, 0)^T \neq (0, 0)^T$, el método **no ha convergido al óptimo en una sola iteración**.

6. **Discusión de la convergencia:** En funciones no cuadráticas, la aproximación polinómica de segundo orden dada por el desarrollo de Taylor no es exacta en todo el espacio (debido a la presencia de derivadas de orden superior, como las de la exponencial e^x). Por tanto, la dirección y longitud de paso de Newton cometen un error de truncamiento. El método no alcanza el óptimo en una sola iteración, sino que requiere un proceso iterativo. Su principal ventaja es que goza de **convergencia cuadrática local** (es decir, el número de dígitos significativos correctos se duplica aproximadamente en cada iteración una vez que el algoritmo se encuentra lo suficientemente cerca del óptimo x^*).